PROGRAMACIÓN AVANZADA
ING. CIVIL PLAN COMUN– SEDE TEMUCO

" Macro-data Turismo Chile”

Nº Grupo	:	Grupo 14
Integrantes	:	Benjamín Aguayo
		Enzo Illanes
		Jaime Panguinao
Profesor	:	Alex Flores
Curso	:	Programación Avanzada
Fecha	:	03/11/2026
Nota	:	

INFORME Nº2

Resumen del Avance: En este segundo avance se implementó la arquitectura modular del sistema en Python, consolidando los procedimientos de limpieza de datos, tratamiento de valores nulos y transformaciones estructuradas para preparar el dataset antes de la etapa de análisis y generación de reportes.

1. Descripción del Trabajo Desarrollado

En la Sesión 2 de desarrollo se migró el flujo de trabajo monolítico previo hacia una estructura modular bien definida bajo la carpeta proyecto/src/. Este diseño facilita el mantenimiento, la escalabilidad y el testeo unitario de cada componente del pipeline de procesamiento de datos.

2. Componentes e Implementación Técnica

2.1. Modularización de la Aplicación

El código se organizó en módulos independientes con responsabilidades únicas dentro de la arquitectura del software:

```
proyecto/
├── main.py                  # Orquestador principal de la ejecución
├── requirements.txt         # Dependencias (pandas, numpy)
├── src/
│   ├── __init__.py          # Inicializador de paquete
│   ├── carga.py             # Módulo de lectura e ingesta de datos
│   ├── limpieza.py          # Funciones de filtrado y saneamiento
│   ├── transformaciones.py  # Transformaciones de negocio y casting
│   ├── validaciones.py      # Validaciones de esquemas e integridad
│   └── reporte.py           # Generación de resultados y exportación
└── datos/
    ├── originales/          # Data cruda (input)
    └── procesados/          # Data limpia y transformada (output)
```

2.2. Limpieza de Datos

El módulo limpieza.py aborda la eliminación de inconsistencias detectadas en la fase exploratoria previa. Se implementaron los siguientes procedimientos:

- **Normalización de cadenas:** Eliminación de espacios en blanco al inicio/final (strip) y conversión de texto a minúsculas en columnas categóricas.
- **Eliminación de duplicados:** Filtrado de filas idénticas o registros redundantes basados en claves primarias.
- **Saneamiento de caracteres especiales:** Corrección de formatos de codificación y eliminación de símbolos no alfanuméricos en atributos de texto.

2.3. Tratamiento de Valores Nulos

Se definieron estrategias diferenciadas según el tipo de variable e impacto en el análisis final:

Tipo de Variable	Estrategia Aplicada	Justificación Técnica
Numérica Continua	Imputación por Mediana / Media	Mantiene la distribución sin verse afectada por valores atípicos (outliers).
Categorica / Texto	Imputación por "Sin Información"	Evita sesgar la frecuencia modal de categorías existentes.
Clave Crítica / ID	Eliminación de Registro (dropna)	Garantiza la integridad referencial si la fila carece de identificador primario.

2.4. Transformaciones de Datos

Mediante el módulo transformaciones.py se procesaron los datos limpios para generar nuevas variables de valor agregado:

- **Casting de Tipos de Datos:** Conversión explícita de columnas numéricas a float64/int64 y fechas a formato datetime64.
- **Creación de Variables Derivadas:** Cálculo de indicadores numéricos y categorización en rangos operativos.
- **Escalamiento y Agrupación:** Generación de agregaciones mediante groupby para facilitar las visualizaciones finales.

3. Conclusiones

La estructuración modular implementada en el avance 2 permite ejecutar un flujo ETL transparente, robusto y automatizado mediante el script principal main.py. Se logró asegurar la calidad e integridad de los datos procesados. Para la siguiente sesión se desarrollará la fase de visualización y exportación automatizada de reportes finales.

Bibliografía

- McKinney, W. (2022). Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter (3rd ed.). O'Reilly Media.
- Sweigart, A. (2019). Automate the Boring Stuff with Python: Practical Programming for Total Beginners (2nd ed.). No Starch Press.